НИУ ВШЭ НН. Факультет ИМиКН. Методы анализа данных.
Charge de cours: В.А. Калягин.
Домашнее задание 1: данные, пропуски, выбросы, методы снижения размерности (PCA, MDS, UMAP, …)
Провести необходимые вычисления. Полученные результаты снабдить подробным комментарием.
Задача. В Excel таблице собраны персональные данные клиентов банка. Столбцы таблицы отражают следующие сведения о клиенте

1	2	3	4	5	6
Возраст (лет)	Количество иждивенцев	Доход (руб./мес.)	Срок проживания в регионе (лет)	Оценка автомобиля заемщика (USD)	Размер кредита (тыс. руб.)

Данные. **Выполнить первичную обработку данных. Сделать первые выводы.**
1. Рассмотрите данные и вычислите основные характеристики признаков: среднее, стандартное отклонение, медиана, квартили. Постройте гистограммы признаков и блок диаграммы признаков. Сделайте первые выводы о возможном распределении признаков.
2. В данных есть пропуски. Подберите из литературы метод восстановления пропущенных данных и заполните пропуски по этому методу.
3. В данных возможны выбросы. Подберите из литературы метод определения выбросов и удалите объекты, идентифицированные как выбросы по этому методу.
Снижение размерности. Метод PCA (Principal Component Analysis=метод главных компонент).
4. Выполнить центрирование данных и такую нормировку, что евклидова норма каждого признака равна 1 (полученная матрица обозначается через Z).
5. Найти SVD разложение матрицы Z (матрицы U, S, V).
6. Исследуйте, сколько скрытых факторов (главные факторы) достаточно для хорошей аппроксимации матрицы данных Z.
7. Замените значения исходных признаков линейными комбинациями главных факторов (матрица Z_k, k – число главных факторов). Вычислите норму разности $\|Z - Z_k\|$ (погрешность аппроксимации) в операторной матричной норме и норме Фробениуса. Сравните с теоретическими оценками.
8. Используя выделенные главные факторы, найти представления клиентов векторами меньшей размерности (размерности k) и построить карту клиентов. Сделать выводы о клиентах банка.
Снижение размерности. Метод MDS (Multidimensional Scaling = многомерное шкалирование)
9. Вычислите расстояние между клиентами любым понравившемся вам способом, кроме евклидова расстояния (расстояние Чебышева, Манхэттенских кварталов, Минковского $p \neq 2$). Проверьте, можно ли клиентов банка поместить в евклидово пространство размерности 2 с сохранением всех вычисленных расстояний между клиентами.
10. Используйте любой из алгоритмов MDS для размещения объектов в евклидовом пространстве размерности 2. Оцените погрешность такого размещения. Постройте карту клиентов. Сравните с картой клиентов из п.8 и сделайте выводы.
Бонус. Методы снижени размерности.
Подберите в литературе метод снижения размерности (UMAP, t-SNE, …) и постройте карту клиентов этим методом. Сравните с картой клиентов построенной по методу PCA.